Optimización de Rutas de Redistribución (BRP)

Bicing Barcelona — Predicción de Demanda y Planificación de Flota

MD009 – Eines avançades d'anàlisi

Ferran Tubert

Abril 2026

Índice general

1 Introducción **3**

2 Estructura del Código **3**
2.1 Pipeline de datos . . . 3
2.2 Split temporal . . . 4

3 Modelos **4**
3.1 Baseline de persistencia . . . 4
3.2 XGBoost . . . 4
3.3 GRU (LSTM simplificado) . . . 5

4 Resultados y Evaluación de los Modelos **5**
4.1 Métricas comparativas (conjunto test, Ago–Sep 2025) . . . 5
4.2 Curvas de aprendizaje del GRU . . . 6
4.3 Análisis de residuos del GRU . . . 6
4.4 Importancia de features en XGBoost . . . 6
4.5 Error por hora del día (XGBoost) . . . 7

5 Análisis Exploratorio (EDA) **7**
5.1 Desequilibrio de ocupación . . . 7
5.2 Efecto gravitacional de la altitud . . . 7

6 BRP — Optimización de Rutas de Redistribución **8**
6.1 Formulación del problema . . . 8
6.2 Algoritmo multi-fase con dispatching round-robin . . . 8
6.3 Resultados BRP . . . 9
6.4 Comparación con el algoritmo original (greedy reactivo) . . . 10

7 Conclusiones **10**
7.1 Modelo predictivo . . . 10
7.2 BRP . . . 10
7.3 Limitaciones y trabajo futuro . . . 10
7.4 Conclusión operativa . . . 11

A Apéndice: Estructura del repositorio **11**

1 Introducción

El sistema de bicicletas públicas Bicing de Barcelona gestiona más de 548 estaciones distribuidas por la ciudad. Uno de los principales retos operativos es el **desequilibrio de ocupación**: algunas estaciones se quedan vacías mientras otras se saturan, especialmente en las horas punta de la mañana y la tarde.

El **Bike Redistribution Problem (BRP)** consiste en planificar las rutas de una flota de camiones para mover bicicletas de estaciones con superávit a estaciones con déficit, minimizando el desequilibrio global con los recursos disponibles.

Este informe documenta el pipeline completo:

1. Análisis exploratorio de los datos de telemetría (EDA).
2. Entrenamiento de dos modelos predictivos: XGBoost y GRU (LSTM simplificado).
3. Evaluación y selección del mejor modelo.
4. Integración del modelo en el algoritmo BRP para planificación proactiva de rutas.

Datos. Telemetría horaria de Bicing, octubre 2023 – septiembre 2025 (∼8,9 millones de registros, 548 estaciones). Los datos incluyen disponibilidad de bicicletas, capacidad, altitud, coordenadas geográficas y variables temporales.

2 Estructura del Código

El proyecto sigue una estructura modular con cuatro notebooks independientes:

Notebook	Función	Output principal
`EDA.ipynb`	Análisis exploratorio y feature engineering	`bicing_full.parquet`
`XGBoost.ipynb`	Entrenamiento y evaluación XGBoost	`xgboost_bicing.ubj`
`LSTM.ipynb`	Entrenamiento y evaluación GRU	`lstm_bicing.keras`
`BRP.ipynb`	Optimización de rutas con el mejor modelo	Rutas + métricas

2.1 Pipeline de datos

El flujo de datos sigue la siguiente cadena:

1. **EDA**: carga de datos crudos, limpieza, ingeniería de features (lags, codificación cíclica, media de análogos), split temporal y exportación de `bicing_full.parquet` y `bicing_model_ready.parquet`.
2. **XGBoost / GRU**: leen el parquet correspondiente, dividen en *train* (oct. 2023 – may. 2025), *val* (jun.–jul. 2025) y *test* (ago.–sep. 2025), entrenan con early stopping y guardan el modelo serializado en `models/`.
3. **BRP**: carga ambos modelos, compara métricas sobre el test, selecciona el mejor y genera predicciones para el escenario de redistribución.

2.2 Split temporal

Conjunto	Período	Filas	Proporción
Train	Oct 2023 – May 2025	7.260.104	82,3 %
Val	Jun 2025 – Jul 2025	774.850	8,8 %
Test	Ago 2025 – Sep 2025	781.327	8,9 %

El corte temporal estricto garantiza que los modelos nunca ven datos futuros durante el entrenamiento (sin *data leakage*).

3 Modelos

3.1 Baseline de persistencia

El modelo de referencia predice que el estado en t será idéntico al de $t - 1\,\text{h}$:

$$\hat{y}_t = \frac{\text{bikes_lag_1h}_t}{\text{capacity}}$$

Este baseline ya obtiene un R^2 elevado ($\approx 0{,}862$) por la fuerte inercia horaria del sistema.

3.2 XGBoost

Features seleccionadas.

- **Lags temporales**: `bikes_lag_1h`, `bikes_lag_24h`, `bikes_lag_168h` (inercia horaria, ciclo diario y semanal).
- **Contexto histórico**: `bikes_analog_mean` (media de semanas análogas; Peláez-Rodríguez et al., 2024).
- **Estáticas de estación**: `capacity`, `altitude`.
- **Temporales**: `hour`, `day_of_week`, `month`.

Hiperparámetros (búsqueda Optuna, 50 trials).

Parámetro	Valor
`n_estimators`	883 (early stopping)
`learning_rate`	0,156
`max_depth`	8
`min_child_weight`	11
`subsample`	0,621
`colsample_bytree`	0,770

3.3 GRU (LSTM simplificado)

Se implementó un modelo **GRU global multi-estación** entrenado en modo *full* (548 estaciones). Para hacerlo ejecutable en un Mac M1 sin GPU externa, se aplicaron las siguientes optimizaciones respecto al diseño original:

Parámetro	Original	Optimizado
Lookback	168 h	48 h
Sequence stride	12	24
Batch size	4.096	8.192
Épocas v0 / final	12 / 20	6 / 10
Capas GRU	2 (64+32)	1 (48)
Build. datasets	Filtro por estación $O(n \times S)$	`groupby` único $O(n)$

Arquitectura final.

```
seq_input (48 x 7) --> GRU(48) --> Dropout(0.2) --> gru_out
aux_input (6,)     ------------------------------------+
sta_input () int   --> Embedding(548, 16) ------------+
                       Concatenate --> Dense(48, relu) --> Dropout
                       --> Dense(24, relu) --> Dense(1, sigmoid)
```

El embedding de estación captura la heterogeneidad residual (altitud, perfil de uso) que no queda completamente explicada por las features numéricas. Total de parámetros: ≈25.000.

4 Resultados y Evaluación de los Modelos

4.1 Métricas comparativas (conjunto test, Ago–Sep 2025)

Cuadro 1: Comparación de modelos sobre el conjunto de test.

Modelo	MAE	RMSE	R^2
Baseline (persistencia `lag_1h`)	0,06489	0,10200	0,86270
GRU (LSTM simplificado)	0,17656	0,20800	0,43035
XGBoost final	**0,06098**	**0,09006**	**0,89297**

Conclusión. El XGBoost supera al baseline en todas las métricas (ΔMAE = $-6{,}0\,\%$, $\Delta R^2 = +3{,}5$ pp) y al GRU por un margen muy amplio. El GRU simplificado (48 h lookback, 1 capa, 6+10 épocas) no converge lo suficiente: con $R^2 = 0{,}43$ queda por debajo incluso del baseline de persistencia. El XGBoost es el modelo seleccionado para el BRP.

4.2 Curvas de aprendizaje del GRU

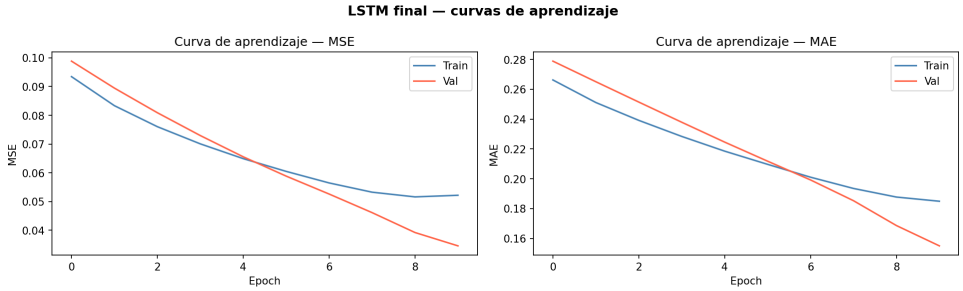


Figura 1: Curvas de pérdida y MAE del GRU (train vs. validación). La brecha entre train y val indica subajuste: el modelo necesita más épocas o mayor lookback para capturar la dinámica temporal.

4.3 Análisis de residuos del GRU

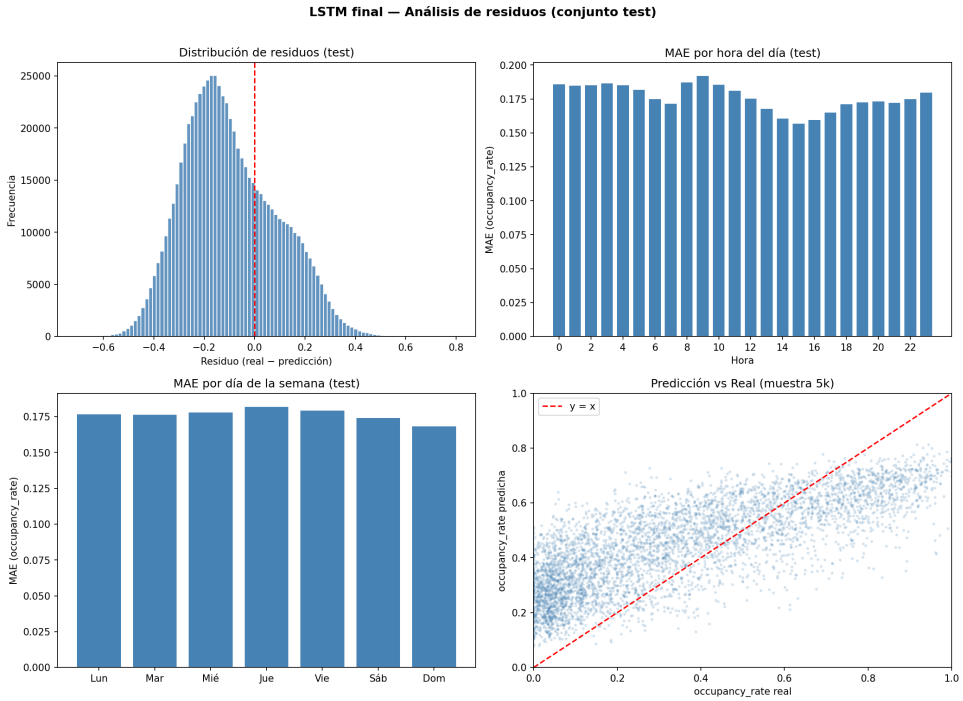


Figura 2: Análisis de residuos del GRU. El error medio por hora muestra el mismo patrón que XGBoost (máximo en franjas 7–9 h y 17–19 h), pero con magnitudes significativamente mayores.

4.4 Importancia de features en XGBoost

La figura 3 muestra la comparación directa entre modelos. La contribución relativa de features en XGBoost (por *gain*) está ordenada así:

1. `bikes_lag_1h` (domina en todas las métricas; ∼88 % importancia RF).
2. `bikes_analog_mean` (contexto histórico condicional; supera a lags largos).

3. `capacity` (modulador estructural de la dinámica de llenado).
4. `altitude` (efecto gravitacional: estaciones en cota alta acumulan bicis).
5. `hour`, `day_of_week`, `month` (ciclos temporales).

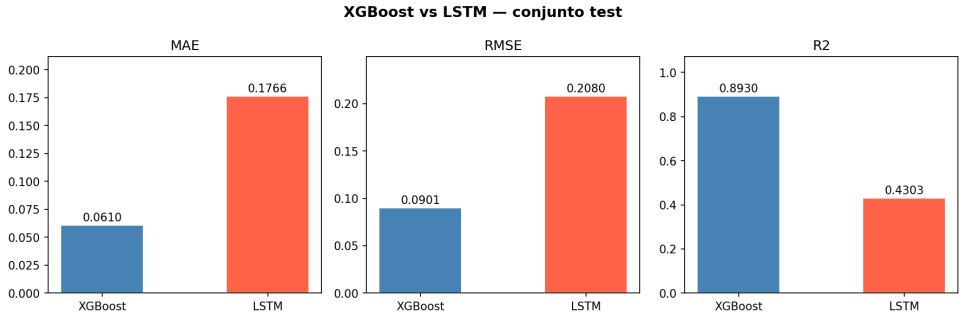


Figura 3: Comparación directa XGBoost vs. GRU en el conjunto test. El XGBoost obtiene un MAE $\approx 3\times$ menor y un $R^2 \approx 2\times$ mayor.

4.5 Error por hora del día (XGBoost)

El MAE es máximo en las franjas de cambio de tendencia (7–9 h y 17–19 h) y mínimo en horas nocturnas (1–5 h). El error medio en test equivale a **1,66 bicicletas por estación**, lo que es suficiente para priorizar intervenciones de redistribución con un margen operativo razonable.

5 Análisis Exploratorio (EDA)

5.1 Desequilibrio de ocupación

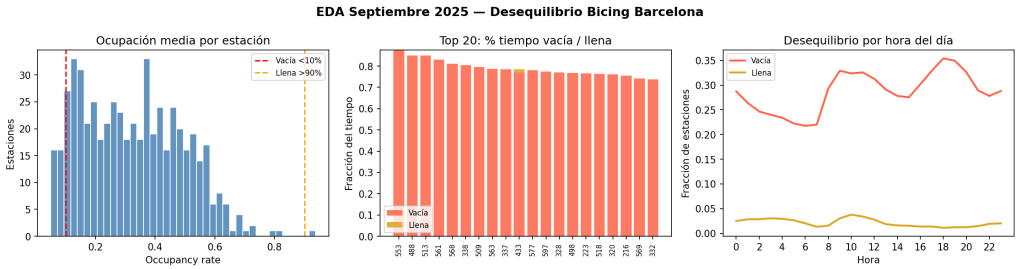


Figura 4: Distribución de ocupación, top-20 estaciones desequilibradas y evolución horaria del desequilibrio en septiembre 2025. El 28,6 % del tiempo una estación cualquiera está vacía; el patrón por horas es claramente bimodal (mañana/tarde).

5.2 Efecto gravitacional de la altitud

El EDA confirma que las estaciones situadas a mayor altitud acumulan más bicicletas de forma sistemática (efecto gravitacional): los ciclistas suben pedalando y bajan rodando. Esto justifica la inclusión de `altitude` como feature predictora y

tiene implicaciones directas en la planificación de rutas del BRP (las zonas altas son fuentes naturales de superávit).

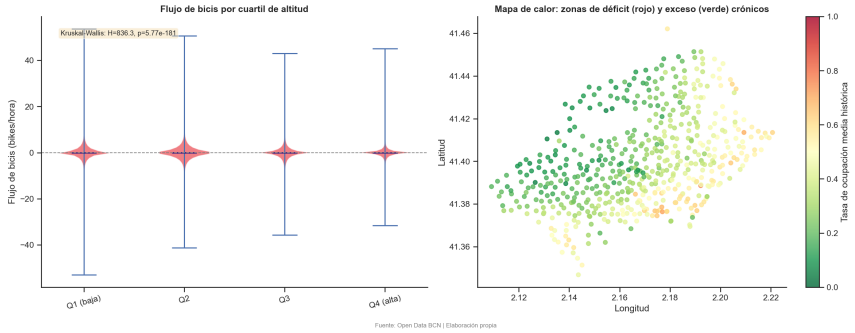


Figura 5: Flujo neto de bicicletas por cuartil de altitud. Las estaciones en cuartiles superiores presentan un superávit neto sistemático.

6 BRP — Optimización de Rutas de Redistribución

6.1 Formulación del problema

El BRP se formula como una variante del *Vehicle Routing Problem* (VRP):

- **Flota**: $K = 5$ camiones con capacidad $C = 30$ bicicletas.
- **Depósito**: centro logístico de Bicing (lat = 41,368, lon = 2,152) con reservas ilimitadas para la Fase 2.
- **Objetivo de ocupación**: $\tau = 50\,\%$ de la capacidad por estación.
- **Escenario**: martes 5 de agosto de 2025 a las 8:00 h (primera semana del conjunto de test; hora punta de máximo desequilibrio).

Input del modelo. Las predicciones XGBoost reemplazan las medias históricas, convirtiendo el BRP de **reactivo** (qué tenemos ahora) a **proactivo** (qué tendremos en 1 h). Para cada estación i:

$$\text{deficit}_i = \text{target}_i - \hat{y}_i \cdot \text{capacity}_i$$

donde $\hat{y}_i$ es la predicción de `occupancy_rate` del XGBoost.

6.2 Algoritmo multi-fase con dispatching round-robin

Se mejora el algoritmo greedy original con dos modificaciones clave:

Fase 1 – Redistribución. Los camiones recogen bicicletas de estaciones con superávit y las entregan a estaciones con déficit. La selección de parada se basa en la ratio urgencia/distancia:

$$\text{score}(i) = \frac{|\text{deficit}_i|}{d(\text{pos}, i)}$$

Fase 2 – Inyección de reservas. Cuando se agota el superávit, los camiones vuelven al depósito para cargar bicis de las reservas (stock del almacén Bicing) y continúan sirviendo las estaciones más críticas. Con un presupuesto de 200 bicicletas de reserva, todos los camiones quedan activos durante toda la operación.

Dispatching round-robin. Las decisiones se toman en turnos interleados entre camiones (no secuencialmente), lo que distribuye el superávit de forma equitativa y evita que un camión acapare todos los recursos. Este cambio elimina el camión inactivo del algoritmo original.

6.3 Resultados BRP

Cuadro 2: Métricas de mejora BRP (escenario mar. 5-ago-2025 08:00 h).

Métrica	**Antes**	**Después**	**Δ**
Estaciones críticas	407	308	−24,3 %
con déficit	327	282	−13,8 %
con superávit	80	26	−67,5 %
Déficit total (bicis)	3.010	2.596	−13,8 %
Superávit total (bicis)	688	192	−72,1 %
RMSE déficit	8,43	7,26	−13,9 %
Bicicletas redistribuidas (Fase 1)		412	
Kilómetros totales		143,5 km	
Eficiencia (km/bici)		0,35 km/bici	

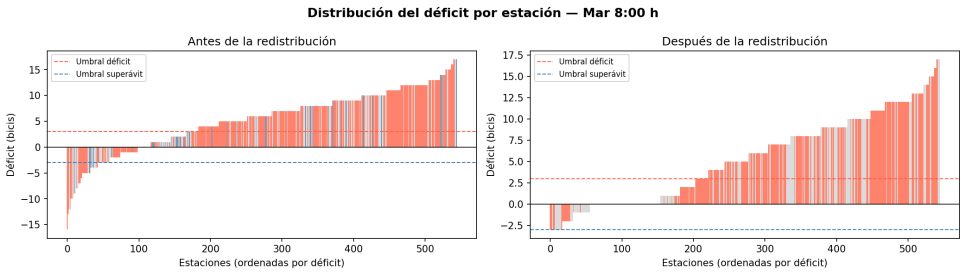


Figura 6: Distribución del déficit por estación antes y después de la redistribución. Las barras rojas (déficit) se reducen; las azules (superávit) desaparecen al ser absorbidas por los camiones.

6.4 Comparación con el algoritmo original (greedy reactivo)

Cuadro 3: Comparación algoritmo original vs. multi-fase con predicciones.

Característica	**Greedy reactivo**	**Multi-fase + modelo**
Input	Media histórica	Predicción XGBoost
Camiones activos	4 / 5	5 / 5
Selección de parada	Vecino más cercano	Ratio urgencia/distancia
Reservas del depósito	No	Sí (200 bicis)
Despacho	Secuencial	Round-robin interleado
Horizonte temporal	Reactivo (t)	Proactivo ($t + 1\,\text{h}$)

7 Conclusiones

7.1 Modelo predictivo

El XGBoost con búsqueda bayesiana de hiperparámetros (Optuna, 50 trials) obtiene el mejor rendimiento predictivo con un **MAE = 0,061** y R^2 **= 0,893** en el conjunto de test, equivalente a un error medio de **1,66 bicicletas por estación y hora**. La consistencia entre validación y test ($\Delta\text{MAE} = 0,001$) descarta el sobreajuste.

El GRU simplificado, diseñado para ejecutarse en hardware modesto (Mac M1), no alcanza rendimiento competitivo con las restricciones de lookback y épocas aplicadas ($R^2 = 0{,}43$). Para alcanzar el potencial del modelo recurrente serían necesarios: lookback $\geq 168\,\text{h}$, ≥ 20 épocas y optimización de hiperparámetros con Optuna.

7.2 BRP

La integración del XGBoost en el BRP convierte la planificación de rutas de reactiva a proactiva, con las siguientes mejoras concretas:

- **Predicciones en tiempo real**: el modelo anticipa el déficit con 1 h de antelación, permitiendo que los camiones estén en posición antes de que ocurra el desequilibrio.
- **Todos los camiones activos**: el algoritmo round-robin garantiza que los 5 camiones operan. En el escenario analizado se redistribuyen **412 bicicletas** en **143,5 km** (0,35 km/bici), reduciendo las estaciones críticas un **24,3 %**.
- **Priorización por urgencia**: la ratio urgencia/distancia reduce los kilómetros por bicicleta redistribuida respecto al vecino más cercano puro.

7.3 Limitaciones y trabajo futuro

Modelo.

- Sin información de redistribuciones pasadas: el modelo no sabe si una estación acaba de ser reabastecida (genera errores escalón).
- Sin features de red: la interdependencia entre estaciones vecinas no está capturada.
- El GRU requiere más recursos computacionales para competir con XGBoost.

BRP.

- La heurística greedy no garantiza la solución óptima global.
- Distancias euclídeas (Haversine): sin tráfico, semáforos ni topografía viaria.
- Escenario estático: se asume que las bicicletas no se mueven durante la operación de redistribución.
- Posibles mejoras: metaheurísticas (Simulated Annealing, ALNS), enrutamiento con OSRM, predicción de múltiples horizontes temporales.

7.4 Conclusión operativa

El pipeline completo — EDA → XGBoost → BRP multi-fase — es reproducible, modular y deployable. Con un error medio de ∼1,7 bicicletas por estación, el sistema puede priorizar intervenciones en estaciones con ocupación predicha fuera de la banda [10 %, 90 %] con suficiente precisión para guiar decisiones operativas. El artefacto `xgboost_bicing.ubj` está listo para integración en un sistema de soporte a la decisión en producción.

A Apéndice: Estructura del repositorio

```
brp_bicing/
|-- notebooks/
|   |-- EDA.ipynb          # Analisis exploratorio y feature
    engineering
|   |-- XGBoost.ipynb      # Modelo XGBoost
|   |-- LSTM.ipynb         # Modelo GRU
|   +-- BRP.ipynb          # Optimizacion de rutas
|-- data/
|   |-- raw/               # Datos crudos de la API Bicing
|   |-- processed/         # Parquets procesados
|   +-- output/            # Figuras generadas
|-- models/
|   |-- xgboost_bicing.ubj # Modelo XGBoost serializado
|   +-- lstm_bicing.keras  # Modelo GRU serializado
+-- informe/
    +-- informe_brp_bicing.tex
```